

Einführung in die Programmierung II

Such- und Sortierv Verfahren

Reiner Hüchting

2. März 2022

Themenüberblick – Bäume

Bäume

Binäre Suchbäume

Balancierte Bäume

Heaps

Speicherung von Bäumen

Themenüberblick – Bäume

Bäume

Binäre Suchbäume

Balancierte Bäume

Heaps

Speicherung von Bäumen

Bäume

Wiederholung: Binäre Suche

- + Halbierung des Suchraums in jedem Schritt
- Liste muss sortiert sein
- Nachträgliches Sortieren ist keine Option (**zu langsam**)

Idee: Elemente direkt an der richtigen Stelle einfügen.

- ▶ Bei Arrays zwei Möglichkeiten:
 1. Richtige Stelle suchen und dann Elemente verschieben.
 2. Vertauschungen wie z.B. bei Insertionsort.
- ▶ Bei verketteten Listen kann direkt eingefügt werden.

Bäume

Gesucht: Datenstruktur für effizientes Einfügen von Elementen

- ▶ Kein Verschieben von Elementen
- ▶ Suchraum sollte mit jedem Schritt halbiert werden.

Idee:

- ▶ Pointerstruktur wie bei verketteten Listen.
- ▶ Jedes Element hat zwei Nachfolger:
 1. kleinere Elemente
 2. größere Elemente
- ▶ i.W. immer noch eine verkettete Liste
 - ▶ Struktur reflektiert das Verhalten der Suche.

Bäume

Definition (Graph)

Ein **Graph** ist ein Tupel (V, E) mit folgenden Eigenschaften:

- ▶ V ist eine Menge von **Knoten**.
- ▶ $E \subseteq V \times V$ ist eine Menge von **Kanten**.

Intuition:

- ▶ Knoten sind zu ordnende **Objekte** (Datensätze).
- ▶ Kanten sind **Verweise** zwischen den Knoten (meist **Pointer**).
- ▶ Unterscheidung: **gerichtete** und **ungerichtete** Graphen
 - ▶ Bei ungerichteten Graphen haben Kanten keine Richtung.
 - ▶ Zu jeder Kante gibt es eine Kante in die Rückrichtung.

Bäume

Definition (Baum)

Ein **Baum** ist ein gerichteter Graph mit folgenden Eigenschaften:

- ▶ Jedes Element hat höchstens einen Vorgänger.
- ▶ Es gibt genau ein Element ohne Vorgänger (die **Wurzel**).

Anders ausgedrückt:

„Ein Baum ist ein **zusammenhängender gerichteter azyklischer Graph**, bei dem jedes Element höchstens einen Vorgänger hat.“

Definition (Binärbaum)

Ein **Binärbaum** ist ein Baum, bei dem jedes Element höchstens zwei Nachfolger hat.

Bäume

Sprechweise

- ▶ Nachfolger eines Knotens heißen **Kinder**.
- ▶ Ein Knoten ohne Kinder ist ein **Blatt**.
- ▶ Kinder werden meist in **linke** und **rechte** Kinder unterteilt.
- ▶ Ein Kind eines Knotes ist die Wurzel eines **Teilbaums**.

Themenüberblick – Bäume

Bäume

Binäre Suchbäume

Balancierte Bäume

Heaps

Speicherung von Bäumen

Binäre Suchbäume

Definition (Binärer Suchbaum)

Ein **binärer Suchbaum** ist ein Binärbaum, für den gilt:

- ▶ Jedem Knoten ist ein **Schlüssel** zugeordnet.
 - ▶ Auf den Schlüsseln ist eine **totale Ordnung** definiert.
 - ▶ D.h. man kann sie vergleichen.
- ▶ Für jeden Knoten gilt die **In-Order-Eigenschaft**:
 - ▶ Die Elemente des linken Teilbaums sind kleiner.
 - ▶ Die Elemente des rechten Teilbaums sind größer.

Motivation

- ▶ Oft als **Wörterbücher** verwendet.
 - ▶ Suche nach einem **Schlüssel** liefert dazugehörigen **Wert**.
- ▶ Stichwörter in Programmiersprachen:
 - ▶ Map, assoziatives Array, Dictionary, Key-Value-Paare

Binäre Suchbäume

Suchen von Elementen

Ansatz: Wie bei der binären Suche.

- ▶ Steige bei der Suche in den Baum hinab.
- ▶ Gehe jeweils nach links oder rechts, wenn der gesuchte Wert kleiner oder größer als der aktuelle Knoten ist.
- ▶ Ergebnis ist der Wert zum gesuchten Schlüssel.

Algorithmus:

1. Starte bei Wurzel.
2. Falls aktueller Knoten leer: **NICHT GEFUNDEN**.
3. Vergleiche gesuchten Wert mit Wert des aktuellen Knotens:
 - ▶ Falls gleich: **GEFUNDEN**.
 - ▶ Falls kleiner: Fahre bei linkem Teilbaum fort.
 - ▶ Falls größer: Fahre bei rechtem Teilbaum fort.

Binäre Suchbäume

Anzeige der Elemente im Baum

- ▶ Ein Baum ist der Vorstellung nach immer noch eine Liste.
- ▶ In welcher Reihenfolge werden die Elemente angezeigt?
- ▶ Anzeige in natürlicher Sortierung: **In-Order-Durchlauf**.
 - ▶ Rekursiver Abstieg in den Baum.
 - ▶ Die Wurzel wird **zwischen** den Knoten des linken und des rechten Teilbaumes angezeigt.
- ▶ Alternativen: **Pre-** oder **Post-Order-Durchlauf**.
 - ▶ Die Wurzel wird **vor** bzw. **nach** den Knoten des linken und des rechten Teilbaumes angezeigt.

Binäre Suchbäume

Einfügen von Elementen

Ansatz: Fast wie bei der Suche.

- ▶ Steige in den Baum ab, bis der Knoten als linkes oder rechtes Kind angehängt werden kann.

Algorithmus:

1. Starte bei Wurzel.
2. Falls **aktueller Knoten leer**, füge neuen Datensatz hier ein.
3. Vergleiche neuen Wert mit Wert des aktuellen Knotens:
 - ▶ Falls kleiner: Fahre bei linkem Teilbaum fort.
 - ▶ Falls größer: Fahre bei rechtem Teilbaum fort.

Binäre Suchbäume

Löschen eines Elements

Ansatz: Suche den zu löschenden Wert und „überbrücke“ Pointer darauf ähnlich wie bei einer verketteten Liste.

- ▶ Problem: Der gelöschte Knoten könnte **zwei** Kinder haben.
- ▶ Einfache Lösung: Lösche den gesamten Teilbaum und füge die Kinder nacheinander wieder ein.
- ▶ Besser: Suche **In-Order-Nachfolger** des gelöschten Knotens und setze diesen stattdessen ein.

Binäre Suchbäume

Aufgaben:

1. Entwerfen Sie eine Datenstruktur für Knoten eines binären Suchbaumes.
 - ▶ Überlegen Sie sich geeignete Typen für **Schlüssel** und **Wert**.
 - ▶ Überlegen Sie sich, wie Sie am besten den leeren Knoten repräsentieren.
2. Entwerfen Sie eine Datenstruktur für den binären Suchbaum.
3. Formulieren Sie Funktionen zum Auffinden, Einfügen und Löschen eines Elements sowie für den In-Order-Durchlauf als C-Code.

Themenüberblick – Bäume

Bäume

Binäre Suchbäume

Balancierte Bäume

Heaps

Speicherung von Bäumen

Balancierte Bäume

Zusammenfassung: Eigenschaften von Suchbäumen

- ▶ Datenstruktur zum effizienten Speichern von Listen.
- ▶ geordnete Speicherung von Werten:
 - ▶ Linker Teilbaum enthält kleinere Werte als die Wurzel.
 - ▶ Rechter Teilbaum enthält größere Werte als die Wurzel.
- ▶ Neue Werte werden direkt an der richtigen Stelle eingefügt.
- ▶ Dadurch schnelles Suchen, Einfügen und Löschen von Werten.

Problem: Bäume können aus der Balance geraten.

- ▶ Neue Elemente werden ggf. nur auf einer Seite angehängt.
- ▶ Der Baum wird zu einer einfach verketteten Liste.
- ▶ Man spricht von einem **entarteten Baum**.

Balancierte Bäume

Definition (Tiefe eines Knotens in einem Baum)

Die **Tiefe** eines Knotens ist die Länge des Pfades bis zur Wurzel.

- ▶ Die Wurzel hat Tiefe 0.
- ▶ Die Kinder der Wurzel haben Tiefe 1.
- ▶ ...

Definition (Höhe eines Baumes)

Die **Höhe** eines Baumes ist die maximale Länge eines Pfades von der Wurzel bis zu einem Blatt.

- ▶ alternativ: Die Höhe ist die maximale Tiefe eines Knotens.

Balancierte Bäume

Definition (Balancierter Baum)

Ein Baum ist **balanciert**, wenn für jeden Knoten gilt, dass sich die Höhe des linken und rechten Teilbaumes höchstens um ein bestimmtes Verhältnis unterscheiden.

- ▶ Dafür muss der Baum ggf. nach Einfügen oder Löschen eines Elements **reorganisiert** werden.
- ▶ Hilfreiches Maß: **Balancefaktor** bf eines Knotens k .
 - ▶ $bf(k)$ ist die Differenz zwischen der Höhe des rechten Teilbaumes und der Höhe des linken Teilbaumes.
 - ▶ $bf(k) = h(\text{rechtes Kind}) - h(\text{linkes Kind})$

Aufgabe: Entwerfen Sie Algorithmen, die ...

1. ...die Tiefe eines Knotens in einem Baum bestimmen.
2. ...die Höhe eines Baumes bestimmen.
3. ...den Balancefaktor jedes Knotens ausgeben.

Balancierte Bäume

Definition (AVL-Baum)

Ein **AVL-Baum** ist ein binärer Suchbaum, bei dem der Balancefaktor jedes Knotens im Bereich $\{-1, 0, 1\}$ liegt.

Erhaltung der AVL-Eigenschaft

- ▶ Beim Einfügen oder Löschen kann die Eigenschaft verloren gehen.
- ▶ Der Baum (oder ein Teilbaum) muss **rotiert** werden.
- ▶ Intuitiv: **nach rechts Rotieren** bedeutet, die Wurzel in den rechten Teilbaum zu verschieben und eine neue Wurzel aus dem linken Teilbaum zu holen.

Balancierte Bäume

Rotationsarten (Einfachrotationen)

- ▶ Links-Rotation:
 - ▶ Wurzel wird in den linken Teilbaum abgesenkt.
 - ▶ Rechtes Kind wird die neue Wurzel.
 - ▶ Linkes Kind der neuen Wurzel wird zum rechten Kind der alten.
- ▶ Rechts-Rotation:
 - ▶ Wurzel wird in den rechten Teilbaum abgesenkt.
 - ▶ Linkes Kind wird die neue Wurzel.
 - ▶ Rechtes Kind der neuen Wurzel wird zum linken Kind der alten.

Diese beiden Rotationen stellen die Balance wieder her, wenn das Ungleichgewicht **ganz außen** im Baum ist.

Balancierte Bäume

Ungleichgewichtssituationen

Wir unterscheiden, auf welcher Seite des Baumes das Ungleichgewicht besteht:

Links-Links

- ▶ Balancefaktoren der Wurzel und des linken Kindes negativ.
- ▶ Balance wird durch Rechtsrotation wieder hergestellt.

Rechts-Rechts

- ▶ Balancefaktoren der Wurzel und des rechten Kindes positiv.
- ▶ Balance wird durch Linkssrotation wieder hergestellt.

Balancierte Bäume

Ungleichgewichtssituationen

Entsprechend gibt es noch die Situationen *Links-Rechts* und *Rechts-Links*:

Links-Rechts

- ▶ Balancefaktor der Wurzel negativ.
- ▶ Balancefaktor des linken Kindes positiv.
- ▶ Balance wird durch **Links-Rechts-Rotation** wieder hergestellt:
 1. Linksrotation durch das linke Kind.
 2. Rechtsrotation durch die Wurzel.

Balancierte Bäume

Ungleichgewichtssituationen

Entsprechend gibt es noch die Situationen *Links-Rechts* und *Rechts-Links*:

Rechts-Links

- ▶ Balancefaktor der Wurzel positiv.
- ▶ Balancefaktor des rechten Kindes negativ.
- ▶ Balance wird durch **Rechts-Links-Rotation** wieder hergestellt:
 1. Rechtsrotation durch das rechte Kind.
 2. Linksrotation durch die Wurzel.

Balancierte Bäume

Implementierung von AVL-Bäumen

- ▶ Einfügen und Löschen wie bisher.
- ▶ Dabei zusätzlich Balancefaktoren berechnen.
- ▶ Sobald ein Knoten mit Balancefaktor -2 gefunden wird, linkes Kind prüfen:
 - ▶ Kind hat Balancefaktor -1 : Rechtsrotation
 - ▶ Kind hat Balancefaktor $+1$: Links-Rechts-Rotation
- ▶ Sobald ein Knoten mit Balancefaktor $+2$ gefunden wird, rechtes Kind prüfen:
 - ▶ Kind hat Balancefaktor $+1$: Linksrotation
 - ▶ Kind hat Balancefaktor -1 : Rechts-Links-Rotation

Balancierte Bäume

Weitere Idee: Abschwächung des AVL-Prinzips

- ▶ Keine perfekte, sondern näherungsweise Balancierung.
- ▶ Idee: Knoten in rot oder schwarz einfärben.
 - ▶ Baum ist balanciert, wenn man nur schwarze Knoten betrachtet.
 - ▶ Anzahl der roten Knoten ist begrenzt.
- ▶ Vorteil: Es muss nicht jedes Mal neu balanciert werden.

Definition (Rot-Schwarz-Bäume)

Ein **Rot-Schwarz-Baum** ist ein Binärbaum, bei dem jeder Knoten eine Farbe (Rot oder Schwarz) hat.

- ▶ Jedes Blatt ist schwarz.
- ▶ Ein roter Knoten hat nur schwarze Kinder.
- ▶ Jeder Pfad von einem Knoten zu seinen Blättern hat die gleiche Anzahl schwarzer Knoten.

Balancierte Bäume

Optimierung des Suchbaumprinzips: B-Bäume

Bei einem **B-Baum** kann ein Knoten mehr als zwei Kinder haben und mehr als einen Schlüssel tragen.

- ▶ Trägt der Knoten n Schlüssel, so hat er $n + 1$ Kinder.
- ▶ Kind 0 enthält Werte, die kleiner sind als der erste Schlüssel.
- ▶ Kind 1 enthält Werte, die zwischen erstem und zweitem Schlüssel liegen usw.

Eigenschaften

- ▶ Die Anzahl der Schlüssel pro Knoten ist variabel
 - ▶ Meist zwischen n und $2n$ für vorgegebene Zahl n .
- ▶ Alle Blätter haben die gleiche Tiefe.
 - ▶ ggf. Zusatzschlüssel in inneren Knoten benutzen.

B-Bäume sind eine typische Datenstruktur in Datenbanken und Dateisystemen.

Themenüberblick – Bäume

Bäume

Binäre Suchbäume

Balancierte Bäume

Heaps

Speicherung von Bäumen

Heaps

Bisheriger Ansatz: Bäume als Listen

- + Suchbaumeigenschaft garantiert korrekte Sortierung.
- + Balancierungsoperationen für schnellen Zugriff.
- Problem: Selbst AVL-Bäume können noch unnötig hoch werden.

Alternatives Gütekriterium: Vollständigkeit

- ▶ Versuche, den Baum möglichst perfekt zu balancieren.
- ▶ Verzichte dafür auf korrekte Sortierung.
 - ▶ Baum sollte immer noch partiell sortiert sein.

Heaps

Definition (vollständiger Binärbaum)

Ein vollständiger Binärbaum ist ein Binärbaum, bei dem alle Ebenen voll besetzt sind.

- ▶ Ausnahme: Die unterste Ebene muss nicht vollständig sein. In diesem Fall sind die Knoten von links durchgehend besetzt.

Intuition

- ▶ Jeder Knoten (außer den Blättern) hat zwei Kinder.
- ▶ Vollständige Bäume sind der Idealfall:
Perfekt balanciert und minimale Suchtiefe.

Heaps

Definition (Heap)

Ein **Heap** ist ein vollständiger Binärbaum, bei dem der Wert jedes Knotens kleiner ist als der seiner Kinder.

Beobachtungen

- ▶ Die Wurzel ist das kleinste Element.
- ▶ Der Baum ist **partiell sortiert**:
Beim Absteigen werden die Elemente größer.

Alternative Definitionen:

- ▶ Ein Heap wie oben definiert heißt **min-Heap**.
- ▶ **Max-Heap**: Die Wurzel ist **größer** als ihre Kinder.

Heaps

Verwendung von Listen:

- ▶ Oft muss nicht auf alle Elemente einer Liste schnell zugegriffen werden.
 - ▶ Aufgabenlisten mit Deadlines
 - ▶ Priorisierung von Datenverkehr oder Aufgaben
 - ▶ Suchalgorithmen (z.B. in Navigationssystemen)
- ▶ Nur das Element mit dem geringsten oder höchsten Wert wird sofort gebraucht.
- ▶ Solche Datenstrukturen können effizient mit Heaps implementiert werden.

Heaps

Definition (Priority Queue)

Eine **Priority Queue** ist ein abstrakter Listen-Datentyp, bei dem jedem Element eine Priorität zugeordnet wird. Operationen:

- ▶ insert fügt ein neues Element ein.
- ▶ pop liefert das Element mit der niedrigsten/höchsten Priorität und entfernt es aus der Liste.
- ▶ Optional: peek bzw. top liefert das höchste Element, ohne es zu entfernen.

Heaps

Heaps als Priority Queues

- ▶ Höchstes bzw. niedrigstes Element steht in Wurzel.
- ▶ Kann ohne jeden Aufwand gefunden werden.
- + Sehr gut als Priority Queue geeignet.

Wie funktionieren `insert` und `pop`?

- ▶ Idee: Elemente können – ähnlich wie bei Bubblesort – durch Vertauschungen auf- und absteigen.
- ▶ `insert`:
 1. Füge neues Element am Ende ein.
 2. Lasse Knoten aufsteigen, bis er richtig einsortiert ist.
- ▶ `pop`:
 1. Ersetze Wurzel durch letztes Element.
 2. Lasse neue Wurzel absinken, bis sie richtig einsortiert ist.

Heaps

Aufsteigen von Knoten: Die Operation **Heapify-Up**

$k :=$ Neuer Knoten

while $k < \text{wurzel}(k)$ **do**

 Vertausche k mit $\text{wurzel}(k)$

- Wird auch **Bubble-Up** genannt.

Einsinken von Knoten: Die Operation **Heapify-Down**

$k :=$ Wurzel

while $k >$ eines der Kinder **do**

 Vertausche k mit kleinerem Kind

- Wird auch **Bubble-Down** genannt.

Heaps

Zusammenfassung: Heaps als Priority Queues

- ▶ Niedrigstes/höchstes Element wird sofort gefunden.
- ▶ insert und pop in logarithmischer Zeit möglich.
- ▶ Ähnlich gute Eigenschaften wie Suchbäume.
- + Heap ist immer vollständig.
 - ▶ Einfügen und Löschen sogar etwas schneller.
- Kein geordneter Durchlauf durch den Baum möglich.
 - ▶ Ungeeignet, wenn Elemente sortiert angezeigt werden sollen.

Heaps

Heaps als Sortierhilfe

- ▶ Erinnerung: Selectionsort
 1. Suche und entferne kleinstes Element aus alter Liste.
 2. Füge Element am Ende in neue Liste ein.
- ▶ Optimierung: Speichere alte Liste als Heap.
 - + Schnelleres Auffinden des kleinsten Elements.
- ▶ Resultat: Sortierverfahren wird ähnlich schnell wie Quicksort oder Heapsort.

Heaps

Heapsort

Baue Heap aus Elementen der Liste.

while Heap nicht leer **do**

 Hänge kleinstes Element aus Heap an Liste an.

 Entferne kleinstes Element aus Heap.

Themenüberblick – Bäume

Bäume

Binäre Suchbäume

Balancierte Bäume

Heaps

Speicherung von Bäumen

Speicherung von Bäumen

Vollständige Bäume können sehr effizient gespeichert werden.

- ▶ Knoten durchnummerieren:
 - ▶ Wurzel hat die Nummer 0.
 - ▶ Hat ein Knoten die Nummer n ,
so haben seine Kinder $2n + 1$ und $2n + 2$.
- ▶ Ein vollständiger Binärbaum mit n Knoten kann in einem Array der Länge n gespeichert werden.
- ▶ Dadurch kann z.B. Heapsort **in-place** sortieren.
 - ▶ **Achtung:** Um den Heap nicht im Array verschieben zu müssen, ist es besser, einen Max-Heap zu verwenden und die Liste vom Ende her aufzubauen.